

Actividad 1. Interpretabilidad de modelos

Descargar el dataset de salarios en data science disponible en Kaggle: <https://www.kaggle.com/datasets/arnabchaki/data-science-salaries-2023> y luego aplicar los siguientes pasos:

Entrenamiento

Entrenar un modelo basado en árboles (por ejemplo, Random Forest) con hiperparámetros por defecto, utilizando todas las variables disponibles. Evaluar brevemente su desempeño con las métricas adecuadas.

Diagnóstico Global (PFI)

Analizar la importancia de las variables mediante PFI. Identificar las variables más relevantes y señalar cualquier resultado llamativo o que requiera investigación.

Diagnóstico Local (SHAP)

Seleccionar dos observaciones con predicciones diferentes (por ejemplo, una predicción alta y otra baja, o un caso con error pequeño y otro con error grande).

Para cada una, generar una explicación con SHAP y analizar:

¿Qué variables contribuyeron más? ¿En qué dirección? ¿La explicación es coherente con el análisis global?

Auditoría

A partir de los resultados obtenidos, identificar y justificar los hallazgos más relevantes sobre el comportamiento del modelo.

Para cada hallazgo, discutir brevemente:

- ¿Qué evidencia proporcionan las técnicas de interpretabilidad?
- ¿El comportamiento es razonable para el problema?
- ¿Qué posible causa podría explicar ese comportamiento?
- ¿Qué acción tomarían para investigarlo o corregirlo?

Prestar especial atención a importancias inusualmente altas, variables redundantes o información duplicada y posibles casos de data leakage.

Si detectan leakage, eliminar la variable problemática, reentrenar el modelo y comparar brevemente con el modelo original: performance, importancia de las variables y razonabilidad del comportamiento. No es necesario repetir todo el análisis detallado de interpretabilidad.

Forma de entrega

Enlace a una notebook en un repositorio de acceso público. *Lo importante es que el código esté ejecutado* (que muestre la salida).

Evaluación

- Se evaluará que se haya respetado la consigna y que haya una interpretación adecuada de los resultados.

- No se evaluará la optimización del modelo ni un EDA exhaustivo. El objetivo es interpretar sus resultados.
- Cada diagnóstico debe estar justificado mediante evidencia obtenida a partir de las técnicas de interpretabilidad utilizadas.